Meta-heurísticas para a Resolução do Problema da Mochila 0/1: Algoritmo Genético, Pesquisa Tabu, Otimização por Colónia de Formigas e Algoritmo Memético

Ricardo Marinho, Fernando Lucas, João Soares
Escola Superior de Tecnologia e Gestão (ESTG), Instituto Politécnico do Porto
8010029@estg.ipp.pt, 8030078@estg.ipp.pt, 8090301@estg.ipp.pt

3 de março de 2026

Resumo

O Problema da Mochila 0/1 (0/1 KP) é um dos problemas combinatórios NP-Difícil mais estudados em otimização. Para instâncias de grande dimensão, os métodos exatos tornam-se computacionalmente inviáveis, justificando o recurso a meta-heurísticas. O presente artigo descreve, com rigor técnico, quatro meta-heurísticas de referência: o Algoritmo Genético (AG), a Pesquisa Tabu (PT), a Otimização por Colónia de Formigas (ACO) e o Algoritmo Memético (AM). Estes quatro paradigmas cobrem, respetivamente, a pesquisa evolucionária, a memória adaptativa, a construção estocástica guiada por ferómona e a hibridização entre pesquisa global e local. Para cada abordagem, apresentam-se os fundamentos teóricos, a adaptação ao 0/1 KP e os operadores específicos. A análise comparativa final discute as vantagens relativas de cada paradigma em função das características das instâncias.

Palavras-chave: Problema da Mochila 0/1, Meta-heurísticas, Algoritmo Genético, Pesquisa Tabu, Colónia de Formigas, Algoritmo Memético

I. Introdução

O Problema da Mochila 0/1 (0/1 KP) consiste em selecionar, de um conjunto de n itens indexados em $\{1, \ldots, n\}$, o subconjunto que maximiza o valor total sem exceder a capacidade máxima W do contentor [1]. Formalmente, trata-se do Programa Linear Inteiro:

$$\max\ z = \sum_{i=1}^{n} p_i x_i \ \text{ s.a. } \ \sum_{i=1}^{n} w_i x_i \leq W, \ \ x_i \in \{0,1\} \qquad (1)$$

com $p_i, w_i \in \mathbb{R}^+$. Classificado como NP-Difícil em sentido fraco [2], o 0/1 KP admite resolução exata por programação dinâmica em $\mathcal{O}(nW)$, mas esta complexidade torna-se proibitiva para instâncias de grande escala [3]. Meta-heurísticas constituem assim a alternativa de escolha em contextos práticos, pois permitem obter soluções de boa qualidade em tempo computacional aceitável [4].

Uma meta-heurística é uma estrutura de pesquisa de alto nível que guia procedimentos heurísticos subordinados, equilibrando *intensificação* (explotação de regiões promissoras) e *diversificação* (exploração de novas regiões do espaço de soluções) [4]. Este artigo analisa quatro paradigmas distintos e complementares: o Algoritmo Genético (Secção II), a Pesquisa Tabu (Secção III), a Otimização por Colónia de Formigas (Secção IV) e o Algoritmo Memético (Secção V).

II. Algoritmo Genético

A. Fundamentos Teóricos

O Algoritmo Genético (AG) é uma meta-heurística evolucionária inspirada nos mecanismos de seleção natural, proposta por Holland [5] e consolidada por Goldberg [6]. Opera sobre uma *população* de soluções candidatas, designadas *cromossomas*, que evoluem ao longo de *gerações* por meio de operadores de seleção, cruzamento (*crossover*) e mutação, convergindo progressivamente para regiões de maior aptidão no espaço de soluções. A ideia fundamental é que a combinação de bons *blocos construtivos* (*building blocks*) dá origem a soluções cada vez melhores [6].

B. Adaptação ao 0/1 KP

Cada cromossoma é representado por um vetor binário $\mathbf{x} = (x_1, \ldots, x_n) \in \{0,1\}^n$, onde $x_i = 1$ indica que o item i está selecionado. A função de aptidão é:

$$f(\mathbf{x}) = \sum_{i=1}^{n} p_i x_i - \lambda \cdot \max\left(0, \sum_{i=1}^{n} w_i x_i - W\right) \qquad (2)$$

onde $\lambda > 0$ penaliza soluções infeasíveis. Uma alternativa mais eficaz é um operador de *reparação* que converte soluções infeasíveis em admissíveis, removendo iterativamente o item de menor razão p_i/w_i até a restrição de capacidade ser satisfeita; depois, tenta acrescentar itens ainda não selecionados por ordem decrescente de p_i/w_i enquanto a capacidade o permitir [7]. Chu e Beasley [7] demonstraram a eficácia desta abordagem no conjunto de instâncias de referência *OR-Library*, sendo que a população inicial é gerada aleatoriamente e a seleção é efetuada por torneio ou roleta (*roulette wheel*).

Algoritmo 1 Algoritmo Genético para o 0/1 KP [7]

```
Gerar população inicial P aleatoriamente
Reparar e avaliar f(x), ∀ x ∈ P
enquanto critério de paragem não satisfeito fazer
    P' ← Seleção(P)
    P'' ← Cruzamento(P', p_c)
    P''' ← Mutação(P'', p_m)
    Reparar soluções infeasíveis em P'''
    Avaliar e atualizar P ← Substituição(P, P''')
fim enquanto
devolver melhor x encontrado
```

Os parâmetros críticos são: a taxa de cruzamento $p_c \in [0{,}6\,;\,0{,}9]$ e a taxa de mutação $p_m \in [0{,}001\,;\,0{,}01]$. O operador de cruzamento mais comum é o de dois pontos, enquanto a

mutação binária inverte cada bit com probabilidade p_m. O AG é reconhecido pela sua capacidade de manter diversidade populacional e explorar implicitamente múltiplas regiões do espaço de soluções em paralelo.

III. Pesquisa Tabu

A. Fundamentos Teóricos

A Pesquisa Tabu (PT) é uma meta-heurística de pesquisa local com memória adaptativa, formalizada por Glover [8, 9] e consolidada em [10]. O mecanismo central é a *lista tabu*: uma memória de curto prazo que regista os atributos das transformações (*moves*) recentemente efetuadas, proibindo a sua reversão durante θ iterações (*tabu tenure*). Este mecanismo impede a ciclagem e força a pesquisa a explorar novas regiões, superando ótimos locais [10].

Além da memória de curto prazo, a PT emprega memória de médio e longo prazo para implementar **intensificação** (aprofundar a pesquisa em regiões promissoras) e **diversificação** (perturbar a solução para escapar a bacias de atração locais). O mecanismo de *oscilação estratégica* permite navegar deliberadamente pela fronteira entre soluções admissíveis e não admissíveis, o que é particularmente relevante para o 0/1 KP [12].

B. Adaptação ao 0/1 KP

Para o 0/1 KP, a vizinhança $N(\mathbf{x})$ de uma solução $\mathbf{x}$ é definida pelo conjunto de soluções obtidas por inversão de um único bit (*1-flip*). Em cada iteração, seleciona-se o melhor *move* admissível que não seja tabu, ou que satisfaça um critério de aspiração (e.g., a solução resultante supera o melhor valor global conhecido). A avaliação incremental de Δf quando se inverte x_i é:

$$\Delta f_i = \begin{cases} p_i & \text{se } x_i = 0 \text{ e } w_i \leq W_{\text{res}} \\ -p_i & \text{se } x_i = 1 \end{cases} \tag{3}$$

onde $W_{\text{res}} = W - \sum_j w_j x_j$ é a capacidade residual. Com oscilação estratégica, permite-se temporariamente exceder a capacidade, penalizando a função objetivo com um coeficiente proporcional à violação.

Hanafi e Fréville [12] propuseram uma PT com informação de *restrição substituta* (*surrogate constraint*) para o problema multidimensional (0/1 MKP), obtendo soluções ótimas ou de qualidade superior a todos os métodos anteriores no conjunto de referência da literatura. Glover e Kochenberger [11] desenvolveram o CETS (*Critical Event Tabu Search*), no qual *eventos críticos* definem os momentos de transição entre fases construtiva e destrutiva, orientando a oscilação estratégica de forma mais agressiva e eficaz.

IV. Otimização por Colónia de Formigas

A. Fundamentos Teóricos

A Otimização por Colónia de Formigas (ACO) é uma metaheurística baseada no comportamento de forrageamento coletivo das formigas reais, formalizada por Dorigo, Maniezzo e Colorni [13]. As formigas depositam *ferómona* nos percursos construídos, reforçando probabilisticamente as escolhas que conduziram a boas soluções. Este mecanismo de memória coletiva e indireta (*stigmergy*) dá origem à aprendizagem emergente do enxame [14].

O sistema MAX-MIN Ant System (MMAS), proposto por Stützle e Hoos [15], é atualmente a variante de maior desempenho para problemas combinatórios: limita os níveis de ferómona ao intervalo $[\tau_{min}, \tau_{max}]$, inicializa τ com o valor máximo e reinicializa a ferómona quando a pesquisa estagna.

B. Adaptação ao 0/1 KP

No 0/1 KP, cada formiga constrói uma solução $\mathbf{x} \in \{0,1\}^n$ de forma iterativa, decidindo para cada item i se o inclui ou não, com base na probabilidade:

$$P(x_i = 1) = \frac{\tau_i^\alpha \cdot \eta_i^\beta}{\tau_i^\alpha \cdot \eta_i^\beta + \tau_i'^\alpha} \tag{4}$$

onde τ_i é o nível de ferómona associado à inclusão do item i, $\eta_i = p_i/w_i$ é a informação heurística (razão valor-peso), α e β controlam a influência relativa da ferómona e da heurística, e τ_i' é o nível de ferómona da exclusão [1]. Após a construção de todas as soluções por m formigas, a ferómona é atualizada por:

$$\tau_i \leftarrow (1-\rho)\,\tau_i + \Delta\tau_i^{\text{best}} \tag{5}$$

onde $\rho \in (0,1)$ é a taxa de evaporação e $\Delta\tau_i^{\text{best}}$ é a contribuição da melhor solução da iteração (ou da melhor global, consoante a estratégia). Soluções infeasíveis são reparadas antes da avaliação.

A riqueza do ACO reside no equilíbrio entre exploração (ferómona uniforme) e explotação (reforço das melhores escolhas históricas), bem como no facto de o mecanismo de evaporação implementar naturalmente uma forma de esquecimento que mantém a diversidade da pesquisa [14].

V. Algoritmo Memético

A. Fundamentos Teóricos

O Algoritmo Memético (AM) é um paradigma híbrido que combina pesquisa evolucionária global com procedimentos de pesquisa local intensiva, conceptualizado por Moscato [16] por analogia com a noção de *meme* de Dawkins — a unidade mínima de transferência cultural. Em contraste com o AG puro, no qual os operadores evolucionários operam diretamente sobre os cromossomas sem aprendizagem individual, no AM cada solução é refinada por pesquisa local antes de contribuir para a próxima geração [17]. O AM concretiza assim a ideia de que o conhecimento específico do problema deve ser explorado localmente para acelerar a convergência e melhorar a qualidade das soluções.

Esta hibridização pode ser vista na perspetiva da aprendizagem *Lamarckiana* (os indíviduos melhorados por pesquisa local transmitem as suas características à descendente) ou *Baldwiniana* (a pesquisa local influencia a aptidão avaliada, mas não altera o genótipo). Para problemas combinatórios de alta complexidade como o 0/1 KP, a abordagem Lamarckiana é geralmente preferida pela sua maior eficiência [17].

B. Adaptação ao 0/1 KP

Para o 0/1 KP, o AM combina o AG com um procedimento de pesquisa local do tipo *bit-flip* ou *2-opt binário*. Após cada operação de cruzamento ou mutação, cada indivíduo é submetido a uma pesquisa local que examina a vizinhança $N(\mathbf{x})$ — obtida por inversão de um ou dois bits — e aceita melhorias enquanto $f(\mathbf{x}') > f(\mathbf{x})$. A qualidade do AM depende fortemente do equilíbrio entre a frequência de aplicação da pesquisa local (por exemplo, apenas à descendente produzida em cada geração, e não à po-

pulação inteira) e o número de iterações máximas de cada corrida local [18].

Puchinger e Raidl [18] desenvolveram um AM para o problema da mochila multidimensional (0/1 MKP), combinando um AG com pesquisa local baseada em relaxação de programação linear inteira (ILP). Os resultados computacionais em instâncias de referência demonstram que o AM supera significativamente o AG puro e a PT isolada, em particular em instâncias de elevada correlação entre pesos e valores, que constituem os casos mais difíceis do 0/1 KP [1].

Algoritmo 2 Algoritmo Memético para o 0/1 KP [17]

```
Gerar população inicial P; reparar e avaliar
para cada x ∈ P fazer
    x ← PesquisaLocal(x)
fim para
enquanto critério de paragem não satisfeito fazer
    Selecionar pais x_1, x_2 ∈ P por torneio
    x' ← Cruzamento(x_1, x_2)
    x' ← Mutação(x', p_m)
    x' ← Reparar(x') se infeasível
    x' ← PesquisaLocal(x')                ▷ aprendizagem individual
    Atualizar P: substituir pior se f(x') > f(x_pior)
fim enquanto
devolver melhor x encontrado
```

A função PESQUISALOCAL examina toda a vizinhança 1-*flip* e aplica o melhor movimento de melhoria, repetindo até atingir um ótimo local. Em alternativa, pode usar-se uma estratégia de *first improvement* por razões de eficiência computacional.

VI. Análise Comparativa

As quatro meta-heurísticas abordadas cobrem paradigmas genuinamente distintos: o AG representa a pesquisa evolucionária por recombinação populacional; a PT representa a pesquisa local guíada por memória adaptativa; o ACO representa a construção estocástica coletiva por estigmergia; e o AM representa a hibridização entre pesquisa global e pesquisa local intensiva. Esta diversidade de mecanismos justifica a sua escolha como conjunto representativo para um estudo comparativo.

Tabela 1: Comparação dos quatro paradigmas para o 0/1 KP

Atributo	**AG**	**PT**	**ACO**	**AM**
Tipo de pesquisa	Popul.	Local	Construtiva	Híbrida
Tipo de memória	Implícita	Lista tabu	Ferómona	Ambas
Soluções mantidas	μ	1	m formigas	μ
Diversidade	Alta	Média	Alta	Alta
Intensificação	Média	Alta	Média	Muito alta
Parâm. críticos	p_c, p_m	$\theta, \lvert N\rvert$	ρ, α, β	p_m, LS it.
Complexidade impl.	Média	Média	Alta	Alta
Qualidade esperada	Boa	Muito boa	Boa	Ótima

O AG apresenta a implementação mais acessível e uma diversidade populacional naturalmente elevada, mas não dispõe de mecanismos de intensificação local explícita [6, 7]. A PT supera os ótimos locais através da lista tabu e da oscilação estratégica, sendo especialmente eficaz em instâncias fortemente correlacionadas [12, 10]. O ACO beneficia de uma memória coletiva emergente que guia implicitamente a pesquisa para regiões promissoras, com desempenho robusto em instâncias de média dimensão [14, 15]. O AM, ao combinar evolução global com aprendizagem local, tende a obter os melhores resultados em qualidade de solução, ao custo de maior complexidade de implementação e calibração [17, 18].

Em termos de escalabilidade, para instâncias de $n > 500$ itens, todos os algoritmos requerem estratégias híbridas ou heurísticas de redução (*core concept*) para manter a eficiência computacional [1]. Para instâncias clássicas da *OR-Library*, o AM e a PT reportam consistentemente os melhores resultados [18, 12].

VII. Conclusão

Este artigo apresentou uma descrição rigorosa de quatro meta-heurísticas de referência para a resolução do Problema da Mochila 0/1: o Algoritmo Genético, a Pesquisa Tabu, a Otimização por Colónia de Formigas e o Algoritmo Memético. A seleção destes quatro paradigmas é justificada pela sua complementaridade teórica: cada um implementa um mecanismo distinto de navegação no espaço de soluções, de memória e de equilíbrio entre intensificação e diversificação.

A análise comparativa evidencia que o AM tende a ser superior em qualidade de solução para instâncias desafiadoras, ao explorar sinergias entre pesquisa evolucionária e pesquisa local. A PT destaca-se pela sua capacidade de intensificação e pelo sofisticado mecanismo de memória adaptativa. O ACO é robusto e não requer uma solução inicial, sendo favorável quando se pretênde construção incremental. O AG mantém-se relevante pela sua versatilidade e facilidade de implementação. Em trabalhos futuros, perspetiva-se o estudo de abordagens híbridas que integrem os mecanismos de memória da PT com o componente construtivo do ACO, bem como a aplicação a variantes do KP (multidimensional, quadrático, múltipla mochila).

Referências

[1] H. Kellerer, U. Pferschy e D. Pisinger, *Knapsack Problems*. Berlim: Springer, 2004. doi: 10.1007/978-3-540-24777-7

[2] M. R. Garey e D. S. Johnson, *Computers and Intractability: A Guide to the Theory of NP-Completeness*. Nova Iorque: W. H. Freeman, 1979.

[3] S. Martello e P. Toth, *Knapsack Problems: Algorithms and Computer Implementations*. Chichester: Wiley, 1990.

[4] C. Blum e A. Roli, "Metaheuristics in combinatorial optimization: Overview and conceptual comparison," *ACM Computing Surveys*, vol. 35, n.º 3, pp. 268–308, set. 2003. doi: 10.1145/937503.937505

[5] J. H. Holland, *Adaptation in Natural and Artificial Systems*. Ann Arbor: University of Michigan Press, 1975.

[6] D. E. Goldberg, *Genetic Algorithms in Search, Optimization and Machine Learning*. Reading: Addison-Wesley, 1989.

[7] P. C. Chu e J. E. Beasley, "A genetic algorithm for the multidimensional knapsack problem," *Journal of Heuristics*, vol. 4, n.º 1, pp. 63–86, 1998. doi: 10.1023/A:1009642405419

[8] F. Glover, "Tabu search — Part I," *ORSA Journal on Computing*, vol. 1, n.º 3, pp. 190–206, 1989. doi: 10.1287/ijoc.1.3.190

[9] F. Glover, “Tabu search — Part II,” *ORSA Journal on Computing*, vol. 2, n.º 1, pp. 4–32, 1990. doi: 10.1287/ijoc.2.1.4

[10] F. Glover e M. Laguna, *Tabu Search*. Boston: Kluwer Academic Publishers, 1997. doi: 10.1007/978-1-4615-6089-0

[11] F. Glover e G. A. Kochenberger, “Critical event tabu search for multidimensional knapsack problems,” in *Meta-Heuristics: Theory and Applications*, I. H. Osman e J. P. Kelly (eds.). Boston: Kluwer, 1996, pp. 407–427. doi: 10.1007/978-1-4613-1361-8_25

[12] S. Hanafi e A. Fréville, “An efficient tabu search approach for the 0–1 multidimensional knapsack problem,” *European Journal of Operational Research*, vol. 106, n.º 2–3, pp. 659–675, abr. 1998. doi: 10.1016/S0377-2217(97)00296-8

[13] M. Dorigo, V. Maniezzo e A. Colorni, “Ant system: Optimization by a colony of cooperating agents,” *IEEE Transactions on Systems, Man, and Cybernetics – Part B*, vol. 26, n.º 1, pp. 29–41, fev. 1996. doi: 10.1109/3477.484436

[14] M. Dorigo e T. Stützle, *Ant Colony Optimization*. Cambridge: MIT Press, 2004.

[15] T. Stützle e H. H. Hoos, “MAX-MIN ant system,” *Future Generation Computer Systems*, vol. 16, n.º 9, pp. 889–914, jun. 2000. doi: 10.1016/S0167-739X(99)00043-1

[16] P. Moscato, “On evolution, search, optimization, genetic algorithms and martial arts: Towards memetic algorithms,” *Caltech Concurrent Computation Program, C3P Report 826*, California Institute of Technology, Pasadena, EUA, 1989.

[17] F. Neri e C. Cotta, “Memetic algorithms and memetic computing optimization: A literature review,” *Swarm and Evolutionary Computation*, vol. 2, pp. 1–14, fev. 2012. doi: 10.1016/j.swevo.2011.11.003

[18] J. Puchinger, G. R. Raidl e U. Pferschy, “The multidimensional knapsack problem: Structure and algorithms,” *INFORMS Journal on Computing*, vol. 22, n.º 2, pp. 250–265, 2010. doi: 10.1287/ijoc.1090.0344